



CCT

CENTRO DE CIÊNCIAS TECNOLÓGICAS

Métodos Quantitativos

UNID1 – Estatística descritiva para interpretação de base de dados

Prof. Me. Ricardo Carubbi (carubbi@unifor.br)

1 MEDIDAS DE POSIÇÃO

1.1 Conceitos

- Estatísticas descritivas que resumem um conjunto de dados, indicando onde os dados estão centralizados ou localizados numa distribuição (medidas de centralidade);
- As medidas de posição se dão em duas formas:
 - **Dados agrupados;**
 - **Dados não agrupados** (contínuos ou discretos).
- As principais medidas de posição são:
 - **Médias** aritmética, ponderada, harmônica, geométrica e recortada;
 - **Medianas**, quartis, decis e percentis (medidas separatrizes);
 - **Modas.**

1 MEDIDAS DE POSIÇÃO




Figura 1 - Comparação das posições das medidas de tendência central em diferentes distribuições. (a) Distribuição perfeitamente simétrica: todas as medidas coincidem. (b) e (c) Distribuições assimétricas, enviesadas à esquerda e direita, respectivamente: as posições da média, mediana e moda são diferentes e seguem aproximadamente a relação empírica apresentada acima.

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- A **média aritmética**, ou simplesmente média, é a soma de todas as observações dividida pelo número total de observações.
- Refere-se ao ponto de equilíbrio dos dados e é sensível a valores extremos (outliers).

Def. 1: Seja $x_1, x_2, \dots, x_n$ uma amostra com n observações de dados contínuos, define-se a média amostral como

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{Eq. 1.1})$$

onde:

- $\bar{X}$ é a média;
- x_i são os valores dos dados;
- n é o número total de observações.

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2a

O clima em Los Angeles é seco na maior parte do tempo, mas pode ser bastante chuvoso no inverno. O mês mais chuvoso do ano é fevereiro. A tabela a seguir apresenta a precipitação anual em Los Angeles, em polegadas, para cada fevereiro de 1965 a 2006.

Calcule a média desta amostra.

0,2	0,6	3,1	1,5	0,1	2,4	3,7	0,1	8,9
8,0	4,4	0,1	1,2	8,9	8,0	4,6	3,2	2,8
13,7	1,9	12,7	0,7	11,0	4,9	1,5	5,5	4,1
0,7	7,9	3,5	0,2	0,5	0,3	6,6	0,0	6,1
1,7	3,1	2,6	4,9	1,3	0,1			

Aplicando Eq. 1.1, temos:

$$\bar{X} = \frac{1}{42} \sum_{i=1}^{42} x_i$$

$$\bar{X} = \frac{157,30}{42} = 3,75''$$

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2

O clima em Los Angeles é seco na maior parte do tempo, mas pode ser bastante chuvoso no inverno. O mês mais chuvoso do ano é fevereiro. A tabela a seguir apresenta a precipitação anual em Los Angeles, em polegadas, para cada fevereiro de 1965 a 2006. **Calcule a média desta amostra.**

0,2	0,6	3,1	1,5	0,1	2,4	3,7	0,1	8,9
8,0	4,4	0,1	1,2	8,9	8,0	4,6	3,2	2,8
	1,9		0,7	11,0	4,9	1,5	5,5	4,1
0,7	7,9	3,5	0,2	0,5	0,3	6,6	0,0	6,1
1,7	3,1	2,6	4,9	1,3	0,1			

Aplicando Eq. 1.1 novamente, temos:

$$\bar{X} = \frac{1}{42} \sum_{i=1}^{42} x_i$$
$$\bar{X} = \frac{130,9}{42} = 3,27''$$

* Remoção dos outliers para análises posteriores.

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- A **mediana** é o valor que divide um conjunto de dados ordenados ao meio;
- Assim com a média, é uma medida de centralidade, mas robusta (não é influenciada) em relação a outliers.

Def. 2: Seja $x_1, x_2, \dots, x_n$ uma amostra com n observações ordenadas, define-se a mediana amostral como

$$\tilde{X} = \begin{cases} x_{(\frac{n+1}{2})} & , \text{ para } n \text{ ímpar.} \\ (x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)})/2 & , \text{ para } n \text{ par.} \end{cases} \quad (\text{Eq. 1.2})$$

onde $\tilde{X}$ é a mediana, x_i são os valores ordenados dos dados, e n é o número total de observações.

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2b

Calcule a mediana da amostra dos dados pluviométricos do exercício 1.2a.

0,2	0,6	3,1	1,5	0,1	2,4	3,7	0,1	8,9
8,0	4,4	0,1	1,2	8,9	8,0	4,6	3,2	2,8
13,7	1,9	12,7	0,7	11,0	4,9	1,5	5,5	4,1
0,7	7,9	3,5	0,2	0,5	0,3	6,6	0,0	6,1
1,7	3,1	2,6	4,9	1,3	0,1			

Dados não ordenados

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2b

Calcule a mediana da amostra referentes aos dados pluviométricos do exercício 1.2a.

0	0,1	0,1	0,1	0,1	0,2	0,2	0,3	0,5
0,6	0,7	0,7	1,2	1,3	1,5	1,5	1,7	1,9
2,4	2,6	2,8	3,1	3,1	3,2	3,5	3,7	4,1
4,4	4,6	4,9	4,9	5,5	6,1	6,6	7,9	8
8	8,9	8,9	11	12,7	13,7			

Dados ordenados

Aplicando Eq. 1.2, temos:

$$n = 42 \text{ (par)}$$

$$\tilde{X} = (x_{\frac{42}{2}} + x_{\frac{42}{2}+1})/2$$

$$\tilde{X} = (x_{21} + x_{22})/2$$

$$\tilde{X} = (2,80 + 3,10)/2 = 2,95''$$

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- A **moda** é o valor que ocorre com maior frequência em um conjunto de dados.
- Em uma distribuição de dados, pode haver uma única moda (unimodal), duas modas (bimodal), ou várias modas (multimodal).

Def. 3: *Seja $x_1, x_2, \dots, x_n$ uma amostra com n observações, define-se a moda amostral como*

$$X_m = \max\{f_{x_i}\} \quad (\text{Eq. 1.3})$$

onde

- X_m é a moda,
- x_i são os valores ordenados dos dados.

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2c

Calcule a moda da amostra referentes aos dados pluviométricos do exercício 1.2b.

0,00	1	1,30	1	3,20	1	6,10	1
0,10	4	1,50	2	3,50	1	6,60	1
0,20	2	1,70	1	3,70	1	7,90	1
0,30	1	1,90	1	4,10	1	8,00	2
0,50	1	2,40	1	4,40	1	8,90	2
0,60	1	2,60	1	4,60	1	11,00	1
0,70	2	2,80	1	4,90	2	12,70	1
1,20	1	3,10	2	5,50	1	13,70	1

Aplicando Eq. 1.3, temos:

$$X_m = 0.10''$$

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- **Quartis, Decis e Percentis** são medidas que dividem o conjunto de dados em partes iguais, indicando os pontos de corte das respectivas partes (medidas separatrizes);
- Como as medidas separatrizes dependem da posição relativa dos dados, é essencial que estes estejam ordenados de forma crescente:
 - **Quartis:** Dividem o conjunto de dados em quatro partes (Q_1, Q_2, Q_3).
 - **Decis:** Dividem o conjunto de dados em dez partes ($D_1, D_2, \dots, D_9$).
 - **Percentis:** Dividem o conjunto de dados em cem partes ($P_1, P_2, \dots, P_{99}$).

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- O cálculo de qualquer medida separatriz pode ser expressa em termos da posição relativa de um determinado ponto de corte no conjunto de dados;

Def. 4: Dado um conjunto de dados ordenados $X=\{x_1, x_2, \dots, x_n\}$, a posição P_j da j -ésima medida separatriz pode ser definida por:

$$P_j = \frac{j(n+1)}{m} \quad (\text{Eq. 1.4})$$

onde:

- P_j é a posição da j -ésima medida separatriz no conjunto de dados ordenados;
- j é o índice da medida separatriz desejada (ex., $j=1$ para 1º quartil ou $j=25$ para o 25º percentil);
- n é o número total de observações (dados) no conjunto X .
- m é o número total de partes na divisão dos dados (ex., $m=4$ para quartis ou $m=100$ para percentis).

1 MEDIDAS DE POSIÇÃO


1.2 Dados não agrupados

- Se a posição relativa P_j não for inteira, é necessária uma interpolação linear entre os dois valores adjacentes para determinar a medida separatriz desejada;

Def. 5: A interpolação linear entre dois pontos (x_1, y_1) e (x_2, y_2) pode ser deduzida usando-se proporcionalidade:

$$\frac{y - y_0}{x - x_0} = \frac{y_1 - y_0}{x_1 - x_0} \quad (\text{Eq. 1.5})$$

Sabendo x , temos: $y = y_0 + (y_1 - y_0) \frac{x - x_0}{x_1 - x_0}$ (Eq. 1.6)



1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2b

Calcule os quartis da amostra referentes aos dados pluviométricos do exercício 1.2a.

0	0,1	0,1	0,1	0,1	0,2	0,2	0,3	0,5
0,6	0,7	0,7	1,2	1,3	1,5	1,5	1,7	1,9
2,4	2,6	2,8	3,1	3,1	3,2	3,5	3,7	4,1
4,4	4,6	4,9	4,9	5,5	6,1	6,6	7,9	8
8	8,9	8,9	11	12,7	13,7			

Aplicando Eq. 1.4, temos:


$$P_{25} = \frac{1(42 + 1)}{4} = 10,75 \text{ (entre 10 e 11)}$$

Aplicando Eq. 1.6 para $i=10$, temos:


$$Q_{25} = 0,60 + (0,70 - 0,60) \left(\frac{10,75 - 10}{11 - 10} \right)$$

$$Q_{25} = 0,68''$$

Precipitação em Los Angeles



Precipitação em Los Angeles



1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2c

Calcule as medidas estatísticas para construção de um gráfico de caixa (boxplot) referentes aos dados do exercício 1.2a.

- **Mínimo (Q0):** 0,00
- **1º quartil (Q1):** 0,68
- **Mediana (Q2):** 2,95
- **3º quartil (Q3):** 5,35
- **Máximo (Q4):** 13,70
- **Limite mínimo:** $Q1 - 1,5 \times IQR = -6,27$ (valor mín. 0.00)
- **Limite máximo:** $Q3 + 1,5 \times IQR = 12,33$ (valor máx. 11)
- **Outliers:** 12,70 e 13,70 (fora dos limites inf. e sup.)





Fig. 1 - Variação da Precipitação em Los Angeles: Distribuição das medições de precipitação nos meses de fevereiro, com destaque para outliers, entre 1965 e 2006.


E

Variação de precipitação em Los Angeles nos meses de Fevereiro

Dados de precipitação de 1965 a 2006



Departamento de Energia dos EUA



- 1 Whiskers
- 2 Caixa (IQR)
- 3 Limite superior
- 4 Terceiro quartil (Q3)
- 5 Mediana
- 6 Primeiro quartil (Q1)
- 7 Limite inferior
- 8 Outliers

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2d

Calcule as medidas estatísticas para construção de um histograma referentes aos dados do exercício 1.2a.

- **Amplitude Total (At):**
 $At = x_{max} - x_{min} = 13,7 - 0 = 13,7$
- **Número de classes (k):**
 $k = 1 + 3,3 \log(n) = 1 + 3,3 \log(42) \approx 7$
- **Amplitude de Classe (h):**
 $h = At/k = 13,7/7 \approx 2$ unidades





Fig. 2 - Histograma da Precipitação em Los Angeles:
Distribuição da precipitação em polegadas para o mês de fevereiro entre 1965 e 2006, com a frequência de ocorrências em cada classe exibida.

A

Histograma da Precipitação em Los Angeles

Dados de Fevereiro dos anos de 1965 a 2006



1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- A **média ponderada** é uma medida de tendência central que leva em consideração a importância (ou "peso") de cada valor no conjunto de dados;

Def. 6: *Seja $x_1, x_2, \dots, x_n$ uma amostra com n observações de dados contínuos e seus respectivos pesos amostrais $w_1, w_2, \dots, w_n$, define-se a média ponderada amostral como*

$$\bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i} \quad (\text{Eq. 1.7})$$

onde:

- x_i representa os valores individuais do conjunto de dados.
- w_i são os pesos associados a cada valor x_i .

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2c

Calcule a **média ponderada** referentes aos dados pluviométricos (x_i) do exercício 1.2a com pesos (w_i) hipotéticos que representem a importância relativa da medição.

xi	wi	xi	wi	xi	wi	xi	wi	xi	wi	xi	wi
0,2	1	0,1	1	8,0	4	0,7	1	7,9	4	6,1	3
0,6	2	8,9	5	4,6	3	11	4	3,5	3	1,7	2
3,1	3	8,0	4	3,2	3	4,9	3	0,2	1	3,1	3
1,5	2	4,4	3	2,8	2	1,5	2	0,5	1	2,6	2
0,1	1	0,1	1	13,7	5	5,5	33	0,3	1	4,9	3
2,4	3	1,2	2	1,9	2	4,1	5	6,6	3	1,3	2
3,7	2	8,9	5	12,7	5	0,7	1	0,0	1	0,1	1

Aplicando Eq. 1.7, temos:

$$\bar{x}_w = \frac{\sum_{i=1}^{42} w_i x_i}{\sum_{i=1}^{42} w_i} = \frac{570,40}{106}$$

$$\bar{x}_w = 5,38$$

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- A **média harmônica** é uma medida de tendência central especialmente útil para conjuntos de dados representados por médias de taxas ou razões. Por ex., velocidades em um percurso, eficiência de máquinas ou índices financeiros.

Def. 7: Seja $x_1, x_2, \dots, x_n$ uma amostra com n observações de dados contínuos, define-se a média harmônica amostral como

$$\bar{x}_h = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} \quad (\text{Eq. 1.8})$$

onde:

- x_i representa os valores individuais do conjunto de dados.
- n é o número total de valores.

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2d

Calcule a média harmônica referente ao portfólio de um investidor, distribuído de maneira desigual em 12 companhias com razões P/L (preço/lucro) conforme abaixo.

Valores de mercado (IBOVESPA 2023)

3,63 3,39 3,27 3,32 3,42 3,71 3,79 3,56 3,59
3,48 3,88 4,06

Aplicando Eq. 1.7, temos:

$$\bar{x}_h = \frac{12}{\sum_{i=1}^{12} \frac{1}{x_i}} = \frac{12}{3,35} = 3,58$$

A **média harmônica** é adequada quando estamos lidando com taxas ou grandezas **inversamente proporcionais**. Se as grandezas são **diretamente proporcionais**, como o exemplo de "peças vendidas por semana" ou "acidentes por dia", a média aritmética ou média ponderada são geralmente mais apropriadas.

1 MEDIDAS DE POSIÇÃO

1.2 Dados não agrupados

- A **média geométrica** é uma medida de tendência central que é particularmente útil para conjuntos de dados multiplicativos, como taxas de crescimento. Por ex., cálculo da taxa de crescimento média anual de um investimento ao longo de vários anos.

Def. 8: Seja $x_1, x_2, \dots, x_n$ uma amostra com n observações de dados contínuos e não-negativos, define-se a média geométrica amostral como

$$\bar{x}_g = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}} \quad (\text{Eq. 1.9})$$

onde:

- x_i representa os valores individuais do conjunto de dados.
- n é o número total de valores.

1 MEDIDAS DE POSIÇÃO

EXERCÍCIO 1.2e

Calcule a média geométrica que representa o crescimento médio do Índice Bovespa ao longo dos 12 meses, conforme os valores abaixo de mercado de 2023 (em trilhão).

Valores de mercado (IBOVESPA 2023)

3,63 3,39 3,27 3,32 3,42 3,71 3,79 3,56 3,59
3,48 3,88 4,06

Taxas de crescimento (IBOVESPA 2023)

1,00 0,93 0,96 1,02 1,03 1,08 1,02 0,94 1,01
0,97 1,11 1,05

Aplicando Eq. 1.9, temos:

$$\bar{x}_g = \left(\prod_{i=1}^{12} x_i \right)^{\frac{1}{12}} = 1,01$$

1 MEDIDAS DE POSIÇÃO

1.3 Dados não agrupados

- As **variáveis discretas** são aquelas que podem assumir apenas um número finito ou contável de valores, geralmente inteiros, como número de filhos ou peças defeituosas;
- As principais medidas amostrais de posição para dados discretos são

Média aritmética

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

Mediana

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2}$$

Moda

$$X_m = \max\{f_{x_i}\}$$

Quartis

$$P_j = \frac{j(n+1)}{m}$$

onde:

- n: Número de observações na amostra. x_i : O i -ésimo valor da amostra. $\bar{X}$: Média da amostra.



Obrigado

e até a próxima aula!