



CCT

CENTRO DE CIÊNCIAS TECNOLÓGICAS

Métodos Quantitativos

UNID. 3 – Distribuições de probabilidade contínuas

Prof. Me. Ricardo Carubbi (carubbi@unifor.br)

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.1 Caracterização de uma variável aleatória contínua

- Muitas variáveis aleatórias têm natureza eminentemente contínua, tais como:
 1. tempo de resposta de um sistema computacional;
 2. rendimento de um processo químico;
 3. resistência de um material, etc.
- Variáveis discretas com muitos resultados são frequentemente aproximadas por modelos contínuos. É o caso de:
 1. número de transações por segundo de uma CPU;
 2. número de defeitos numa amostra de 5.000 itens, etc.

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.1 Caracterização de uma variável aleatória contínua

- Um círculo é dividido em n setores de mesmo tamanho 1 a n . Seja a variável aleatória discreta X = número do setor apontado quando o ponteiro para de girar. Teremos:




Figura 1. Representação dos setores onde todos os pontos sejam equiprováveis

- A distribuição de probabilidades de X , quando $n \rightarrow \infty$ pode ser especificada como:

$$P(x) = P(X = x) = \lim_{n \rightarrow \infty} \frac{1}{n} = 0, \quad \forall x = 1, 2, \dots \quad (\text{Eq. 1})$$

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.1 Caracterização de uma variável aleatória contínua

- Seja a variável aleatória contínua X = ângulo formado pela posição do ponteiro.
- Podemos ilustrar a distribuição de probabilidades de X , através da chamada função densidade de probabilidade, que mostra a relação entre uma área e um evento.




Figura 2. (a) Função densidade de probabilidade da variável aleatória X e (b) probabilidade dos eventos $\{0 < X < 90\}$ e (c) $\{30 < X < 60\}$

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.2 Função densidade de probabilidade

- Probabilidades de eventos associados a uma variável aleatória contínua X podem ser calculadas mediante uma função densidade de probabilidade f que deve satisfazer:

$$a) f(x) \geq 0, \forall x \in \mathbb{R} \text{ e} \quad (\text{Eq. 2})$$

$$b) \int_{-\infty}^{\infty} f(x) dx = 1 \quad (\text{Eq. 3})$$

$$c) \text{ Se } A = [a, b], \text{ então } P(A) = \int_a^b f(x) dx \quad (\text{Eq. 4})$$




Figura 3. Área sob a curva representando a probabilidade dos eventos a e b .

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.2 Função de distribuição acumulada

- Seja X uma variável aleatória contínua com função de densidade de probabilidade, definimos sua função de distribuição acumulada por:

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(s) ds, \quad \forall x \in \mathbb{R} \quad (\text{Eq. 5})$$

- Dada a função de distribuição acumulada F , podemos obter a função densidade de probabilidade por:

$$f(x) = \frac{d}{dx} F(x) \quad (\text{Eq. 6})$$

para todo ponto x em que F é derivável.

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.3 Valor esperado e variância

- Uma variável aleatória contínua X , com função densidade de probabilidade, tem valor esperado e variância definidos por:

$$\mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx \quad (\text{Eq. 7})$$

$$\sigma^2 = V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx \quad (\text{Eq. 8})$$

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.3 Exemplo

Seja a variável aleatória T (min) definida como o tempo de resposta na consulta a um banco de dados, conforme **Fig. 4**. Seja $P(T > 3)$, valor esperado $E(T)$ e variância $V(T)$:

$$P(T > 3) = \int_3^{\infty} f(t) dt = \int_3^{\infty} 2e^{-2t} dt = 2 \left[-\frac{1}{2} e^{-2t} \right]_3^{\infty} = 0 + e^{-2(3)} = e^{-6}$$

$$\mu = E(T) = \int_{-\infty}^{\infty} t f(t) dt = \int_{-\infty}^0 t \cdot 0 dt + \int_0^{\infty} t \cdot 2e^{-2t} dt = 0 + 2 \int_0^{\infty} t e^{-2t} dt = \frac{1}{2}$$

Integrar por partes

$$E(T^2) = \int_{-\infty}^{\infty} t^2 f(t) dt = \int_{-\infty}^0 t^2 \cdot 0 dt + \int_0^{\infty} t^2 \cdot 2e^{-2t} dt = 0 + 2 \int_0^{\infty} t^2 e^{-2t} dt = \frac{1}{2}$$

$$\sigma^2 = V(T) = E(T^2) - \mu^2 = \frac{1}{2} - \left(\frac{1}{2} \right)^2 = \frac{1}{4}$$




Figura 4. Função de probabilidade do evento T e área sob a curva representando a probabilidade do evento $T > 3$.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4 Principais Distribuições Contínuas

- Nesta seção, estudaremos três modelos probabilísticos contínuos, que podem ser usados em diversas situações práticas.
 - Distribuição uniforme;
 - Distribuição exponencial;
 - Distribuição normal;
- O problema passa a ser, então, determinar qual modelo é o mais adequado para a situação em estudo e como aplicá-lo adequadamente.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.1 Distribuição de Uniforme

- Relembremos o exemplo, onde tínhamos um círculo e um ponteiro que era colocado a girar. A variável aleatória de interesse era $X = \text{ângulo formado entre a posição que o ponteiro para e a linha horizontal do lado direito}$;
- Supôs-se, também, não existir região de preferência para o ponteiro parar. Nessas condições, podemos considerar que todo intervalo de mesma amplitude, contido em $[0, 360)$, tem a mesma probabilidade de ocorrência;
- É um experimento típico em que a chamada distribuição uniforme é apropriada.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.1 Distribuição de Uniforme

- Uma variável aleatória X tem distribuição uniforme de parâmetros α e β , sendo $\beta > \alpha$, se sua densidade é especificada por:
- Em consequência, sua distribuição acumulada é dada por:

$$f(x) = \begin{cases} \frac{1}{\beta - \alpha}, & \text{para } x \in [\alpha, \beta] \\ 0, & \text{para } x \notin [\alpha, \beta] \end{cases} \quad (\text{Eq. 9})$$

$$F(x) = \begin{cases} 0, & \text{para } x < \alpha \\ \frac{x - \alpha}{\beta - \alpha}, & \text{para } \alpha \leq x < \beta \\ 1, & \text{para } x \geq \beta \end{cases} \quad (\text{Eq. 10})$$




Figura 5. (a) Distribuição uniforme e (b) uniforme acumulada.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.1 Distribuição de Uniforme

- O valor esperado e a variância de uma distribuição uniforme são:

$$E(X) = \frac{\alpha + \beta}{2} \quad (\text{Eq. 11})$$

$$V(X) = \frac{(\beta - \alpha)^2}{12} \quad (\text{Eq. 12})$$

- Note que o valor esperado da distribuição uniforme é exatamente o ponto médio do intervalo $[\alpha, \beta]$, ou seja, nessa distribuição fica evidente que μ representa o centro de gravidade da massa descrita pela função densidade de probabilidade.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.2 Distribuição Exponencial

- A distribuição de Poisson modela o número de ocorrências em um período, enquanto a distribuição exponencial modela o intervalo entre essas ocorrências. Exemplos:
 - tempo (em minutos) até a próxima consulta a um a base de dados;
 - tempo (em segundos) entre pedidos a um servidor;
 - distância (em metros) entre defeitos de uma fita.




Figura 6. Relação entre a distribuição de Poisson e a exponencial.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.5.2 Distribuição Exponencial

- Para chegarmos à formulação matemática da distribuição exponencial, vamos considerar a equivalência entre os dois seguintes eventos:

A primeira ocorrência ser depois do tempo t  Nenhuma ocorrência em $[0, t)$

- Sejam as variáveis aleatórias:
 - X_t = número de ocorrências no intervalo de tempo $[0, t)$; e
 - T = tempo entre as ocorrências.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.2 Distribuição Exponencial

- Sendo λ a taxa média de ocorrências por unidade de tempo, então, considerando independência entre as ocorrências, X_t tem distribuição de Poisson com parâmetro λ_t .
- E a equivalência entre os dois eventos pode ser expressa por:

$$T > t \iff X_t = 0 \quad (\text{Eq. 12})$$

Logo aplicando a expressão de Poisson (ver aula anterior) $p(x) = \frac{e^{-\lambda} \lambda^x}{x!}$

$$P(T > t) = P(X_t = 0) = \frac{e^{-\lambda_t} \lambda_t^0}{0!} = e^{-\lambda t} \quad (\text{Eq. 13})$$

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.2 Distribuição Exponencial

- Usando o evento complementar, podemos definir para todo $t > 0$ a função de distribuição acumulada de uma variável aleatória T com distribuição exponencial:

$$F(t) = P(T \leq t) = 1 - e^{-\lambda t} \quad (\text{Eq. 14})$$

Em consequência, para $t > 0$ temos a função densidade de probabilidade dada por:

$$f(t) = \frac{d}{dt}F(t) = \lambda e^{-\lambda t} \quad (\text{Eq. 15})$$




Figura 7. Representação gráfica da função densidade de probabilidade de uma variável aleatória com distribuição exponencial.

1 VARIÁVEIS ALEATÓRIAS DISCRETAS

1.4.2 Distribuição Exponencial

- Para uma variável aleatória T , com distribuição exponencial de parâmetro λ , temos:

$$E(T) = \frac{1}{\lambda} \quad (\text{Eq. 16})$$

$$V(T) = \frac{1}{\lambda^2} \quad (\text{Eq. 17})$$

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.2 Exemplo

O tempo de vida (em horas) de um transistor é uma variável aleatória T com distribuição exponencial. O tempo médio de vida do transistor é de 500 horas.

$$f(t) = \lambda e^{-\lambda t}, \quad t \geq 0, \quad F(t) = 1 - e^{-\lambda t}, \quad P(T > t) = e^{-\lambda t}, \quad \lambda = \frac{1}{500}.$$

a) Calcule a probabilidade de o transistor durar mais do que 500 horas.

$$P(T > 500) = e^{-\frac{500}{500}} = e^{-1} \approx 0,3679.$$

b) Calcule a probabilidade de o transistor durar entre 300 e 1000 horas.

$$P(300 \leq T \leq 1000) = F(1000) - F(300), \quad F(t) = 1 - e^{-\frac{t}{500}}$$
$$F(1000) = 1 - e^{-\frac{1000}{500}} = 1 - e^{-2}, \quad F(300) = 1 - e^{-\frac{300}{500}} = 1 - e^{-0.6}.$$

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.2 Exemplo (continuação)

- b) Calcule a probabilidade de o transistor durar entre 300 e 1000 horas.

$$P(300 \leq T \leq 1000) = (1 - e^{-2}) - (1 - e^{-0.6}) = e^{-0.6} - e^{-2}.$$

$$P(300 \leq T \leq 1000) \approx 0,5488 - 0,1353 = 0,4135$$

- c) Sabendo-se que o transistor já durou 500 horas, calcule a probabilidade dele durar mais 500 horas.

Pela propriedade de falta de memória da distribuição exponencial¹, ou seja, $P(T > t + s \mid T > t) = P(T > s)$.

$$P(T > 1000 \mid T > 500) = P(T > 500) = e^{-1} \approx 0,3679$$



1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.3 Distribuição Normal

- A distribuição normal é fundamental por modelar fenômenos naturais e por realizar aproximações no cálculo de probabilidades de variáveis com outras distribuições;
- É muito importante também na inferência estatística (amostra populacional);
- Caracterizada por uma função de probabilidade, cujo gráfico descreve uma curva em sino, onde a probabilidade da variável aleatória assume valores próximos do centro.

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.2 Distribuição Normal

Dados os parâmetros $\mu \in \mathbb{R}$ e $\sigma > 0$, a função densidade de probabilidade da normal é dada por:




Figura 8. Representação gráfica da função densidade de probabilidade normal e a indicação de seus dois parâmetros: μ e σ .

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.3 Distribuição Normal



Figura 9. A Figura mostra diferentes curvas normais, em função dos valores de μ e σ . As distribuições da Figura 8 podem representar, por exemplo, medidas da dureza de aço produzido sob diferentes condições. A distribuição (1) representa a dureza do aço em uma situação padrão; e a distribuição (2), as medidas de dureza do aço após um processo de melhoria da qualidade, em que aumentou a dureza média. A distribuição (3) representa as medidas de dureza do aço quando o processo está sob rígido controle; enquanto a distribuição (4) quando fora de controle, o que acarreta aumento na variabilidade.

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.3 Distribuição Normal

- Representaremos uma variável aleatória X com distribuição normal de média μ e variância σ^2 por $X : N(\mu, \sigma^2)$. Seguem outras características do modelo normal:
 - curva é simétrica em torno de μ , em consequência, os valores da média (μ) e da mediana (m_d) são iguais, e também $P(X < \mu - \alpha) = P(X > \mu + \alpha), \forall \alpha \in \mathbb{R}$
 - teoricamente, a curva prolonga-se de $-\infty$ a $+\infty$, sendo $\lim_{x \rightarrow \pm\infty} f(x) = 0$
 - combinação linear de variáveis aleatórias normais é uma variável aleatória normal:

$$X_1 : N(\mu_1, \sigma_1^2) \quad \text{e} \quad X_2 : N(\mu_2, \sigma_2^2), \forall a, b \in \mathbb{R}, \quad Y = aX_1 + bX_2.$$

$$E(Y) = a\mu_1 + b\mu_2 \quad V(Y) = a^2\sigma_1^2 + b^2\sigma_2^2$$

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.3 Distribuição Normal

- Características do modelo normal (continuação):
 - afastamentos da média, em unidades de desvio padrão, preservam a mesma área sob a curva, independentemente dos valores de (μ e σ):




Figura 10. Afastamentos da média, em unidades de desvio padrão, preservam a mesma área sob a curva normal.

1 VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.4 Distribuição Normal Padrão

- Seja $X : N(\mu, \sigma^2)$, então a variável aleatória Z tem distribuição normal com média zero e desvio padrão unitário $Z : N(0,1)$ conhecida como **distribuição normal padrão**.

$$Z = \frac{X - \mu}{\sigma} \quad (\text{Eq. 20})$$

- Qualquer área (probabilidade) sob a densidade de X pode ser avaliada sob a densidade de Z .
- Dessa forma, qualquer problema relativo a uma distribuição normal pode ser pensado em termos da distribuição normal padrão.

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.4 Distribuição Normal Padrão




Figura 11. Transformação do evento $\{X > 180\}$, da distribuição normal de parâmetros $\mu = 170$ e $\sigma = 10$, em um evento da distribuição normal padrão: $\{Z > 1\}$.

1. A propriedade de falta de memória é uma **característica única** da distribuição exponencial. Essa propriedade implica que a distribuição exponencial não "lembra" do passado. Ou seja, o tempo já decorrido t não afeta a probabilidade de o evento ocorrer no futuro. É como se o relógio "reiniciasse" no momento atual.

VARIÁVEIS ALEATÓRIAS CONTÍNUAS

1.4.4 Exemplo

Suponha que a absorção de água (%) em certo tipo de piso cerâmico tenha distribuição normal com média 2,5 e desvio padrão 0,6. Seleccionando, aleatoriamente, uma unidade desse piso, qual é a probabilidade de ele acusar absorção de água entre 2% e 3,5%?

Transformar os valores x em valores padronizados $Z = \frac{X - \mu}{\sigma}$

$$Z_1 = \frac{2 - 2,5}{0,6} = -0,8333, \quad Z_2 = \frac{3,5 - 2,5}{0,6} = 1,6667.$$

Calcular as probabilidades pela função

$$P(2 \leq X \leq 3,5) = P(Z \leq 1,6667) - P(Z \leq -0,8333),$$

$$P(2 \leq X \leq 3,5) = 0,9522 - 0,2023 = 0,7499.$$




Figura 12. Representação da curva normal destacando as áreas acumuladas $P(Z \leq -0,83) \approx 0,2033$ e $P(Z \leq 1,67) \approx 0,9522$.

CENTRO DE CIÊNCIAS TECNOLÓGICAS

1. **DIST.NORMP:** Retorna a função de distribuição acumulada normal padrão no LibreOffice. Sintaxe: DIST.NORMP(Número) Número é o valor para o qual a distribuição acumulada normal padrão é calculada Exemplo DIST.NORMP(1) retorna 0,84. A área abaixo da curva da distribuição normal padrão à esquerda do valor de $X = 1$ é 84% da área total.

Principais Distribuições Discretas

Característica	Uniforme	Exponencial	Normal
Condições de aplicação	Eventos com probabilidade constante em um intervalo definido.	Modela o tempo entre eventos que ocorrem continuamente e de forma independente.	Modela variáveis aleatórias que possuem distribuição simétrica ao redor da média.
Tipo de amostragem	Valores igualmente prováveis num intervalo.	Decaimento exponencial com probabilidade maior para valores menores.	Densidade maior ao redor da média, decaindo conforme se afasta da média.
Dependência dos ensaios	Independentes.	Independentes (falta de memória).	Independentes (no caso de variáveis independentes).
Número de ensaios	Único intervalo ou conjunto fixo.	Infinito (variável contínua, eventos modelados ao longo do tempo).	Infinito (variável contínua, definida para todo o domínio real).
Parâmetros	Limites α e β do intervalo $f(x)=1 / (\beta-\alpha)$, $\alpha \leq x \leq \beta$	Taxa $\lambda>0$: $f(x)=\lambda e^{-\lambda x}$, $x\geq 0$	Média (μ) e desvio padrão (σ)
Exemplos de aplicação	Sorteios, geração de números aleatórios, distribuição de eventos em intervalos fixos.	Tempo de espera em filas, duração de equipamentos, tempo entre chamadas telefônicas.	Altura, peso, medições de processos industriais, erros de medição, preços de ativos financeiros.

1. Eventos raros são eventos que têm uma probabilidade muito baixa de ocorrer em numa sequência de observações. Por exemplo, o cálculo de seguros e políticas de gestão de riscos usam a frequência de eventos raros para definir coberturas e estratégias. Demais exemplos.: desastres naturais graves, acidentes aéreos, defeitos em produtos, doenças raras, etc.



Obrigado

e até a próxima aula!